다자산 ETF 추세추종(터틀 트레이딩) + 머신러닝 메타 라벨링

백테스트 보고서 · 송호빈 · 데이터 기준일 2026-11-04 · 실제 매매 없음(포트폴리오용 검증)

1. 요약

- 대상: 4 대 자산군(주식 10·채권 6·실물 6·통화 3) 미국 상장 ETF 25 개. ETF 상장 전 구간은 같은 자산을 추종하는 인덱스 펀드로 이어 붙이고, 각 자산은 데이터가 쌓인 시점부터 편입(1998 년 13 개 → 2013 년 초부터 25 개).
- 방법: 터틀 20 일 돌파 신호(1 차 모델) + '이 신호가 20 거래일 뒤 수익일 확률'을 예측하는 로지스틱 회귀(2 차 모델). 1998~2007 년으로 학습하고 매년 다시 학습, 2008-01~2026-11 을 처음 보는 데이터로 검증.
- 표본 밖 결과: 터틀 규칙 샤프 0.14·최대 낙폭 -4.9%, 터틀+ML 샤프 0.14·최대 낙폭 -5.6%, 리스크 패리티 샤프 0.28·최대 낙폭 -12.0%, 60/40 샤프 0.64·최대 낙폭 -31.4%.
- 위기 구간: 2008 년 터틀 6.0% (60/40 -17.7%), 2022 년 터틀 0.0% (60/40 -16.6%). 추세추종은 큰 하락장에서 손실을 막았지만 횡보·반등장에서 수익이 작았다.
- ML 예측력: 표본 밖 AUC 0.516. 정답을 무작위로 섞어 학습한 '가짜 학습' 20 회 평균 0.496(표준편차 0.015)과 구별되지 않았다. 규칙 대비 알파 t 값 -0.46. 결론: 이 입력 변수들로는 터틀 신호의 성패를 예측할 수 없었다.
- 강건성: 채널을 55 일로 늘리면 샤프 0.33 로 좋아지고 10 일이면 -0.10 로 나빠졌다. 거래비용 2 배에서 터틀 샤프 -0.07. 월간 200 일선 신호가 가장 좋았다(샤프 0.44). 200 일선에 ML 을 붙이면 t 1.92 였지만 가짜 학습도 t -3.5~2.3 가 나와 예측력의 증거로 보기 어렵다.
- 변수 확장(신용 스프레드·금리·자산 간 상관·변동성 국면·돌파 강도·자산군 등 18 개): 부스팅 AUC 0.524 로 가짜 학습 최고값(0.518)을 조금 넘었지만, 포트폴리오에서는 규칙 대비 알파 t -0.21 로 개선이 없었다. 약한 신호가 있어도 비용·비중 조절을 넘을 만큼은 아니었다.

2. 전략 규칙

항목	내용
유니버스	주식(미국 대형·나스닥 100·소형, 유럽, 일본, 신흥국, 한국, 중국, 인도, 중남미) · 채권(미국채 단기·중기·장기, 물가연동채, 투자등급 회사채, 하이일드) · 실물(금, 은, 원유, 원자재 종합, 농산물, 리츠) · 통화(달러 인덱스, 유로, 엔화). 결과를 보기 전에 목록 고정. 다우존스는 S&P500 과 사실상 같은 자산이라 제외, VIX 는 살 수 있는 자산이 아니라 입력 변수로만 사용
1 차 신호(터틀)	종가가 직전 20 일 최고 종가를 넘으면 매수 결정 → 다음 날 종가에 진입. 종가가 직전 20 일 최저 종가 아래 또는 진입가 − 2N(N = 20 일 평균 종가 변동폭) 아래면 청산 결정 → 다음 날 종가에 청산
비중	월말에 자산군 4 개가 위험을 똑같이 나눠 갖고(자산이 있는 자산군 수로 나눔), 자산군 안에서는 자산마다 똑같이 나눈 뒤 60 일 변동성으로 나눔(변동성 역수). 합이 1 = 리스크 패리티. 터틀은 들고 있는 자산만 이 비중, 나머지는 현금(미 3 개월 국채)
2 차 모델(ML)	입력: 200 일선 대비 위치, EMA 21·55·89 정배열, RSI(14), 볼린저 밴드폭, VIX(전일), 장단기 금리차(전일), 신용 스프레드, 신용 스프레드 3 개월 변화, 미국채 10 년 금리, 10 년 금리 3 개월 변화, 자산 간 평균 상관(60 일), 12 개월 수익률, 변동성 국면(20 일÷252 일), 돌파 강도(N 단위), 자산군: 주식, 자산군: 채권, 자산군: 실물, 자산군: 통화. 정답: 진입 후 20 거래일 수익 > 0. 로지스틱 회귀(변수 표준화). 매년 1 월 1 일에 그때까지 정답이 확정된 신호로만 다시 학습(확정 안 된 마지막 20 일치 신호 제외)
ML 비중 배수	배수 = 2 × 예측 확률(0.7 → 1.4 배), 0.3 미만이면 진입 안 함. 합이 100%를 넘으면 100%로 줄임(레버리지 없음)
거래비용	바뀐 비중의 0.05%(편도: 수수료 + 호가 차이)
기간	모의 운용 1998-01-02~2026-11-04, 학습 1998~2007, 표본 밖 검증 2008-01-02~2026-11-04
비교 대상	리스크 패리티(같은 비중을 항상 100% 투자), 60/40(S&P500 60 + 미국채 7~10 년 40, 월 재조정)

3. 데이터

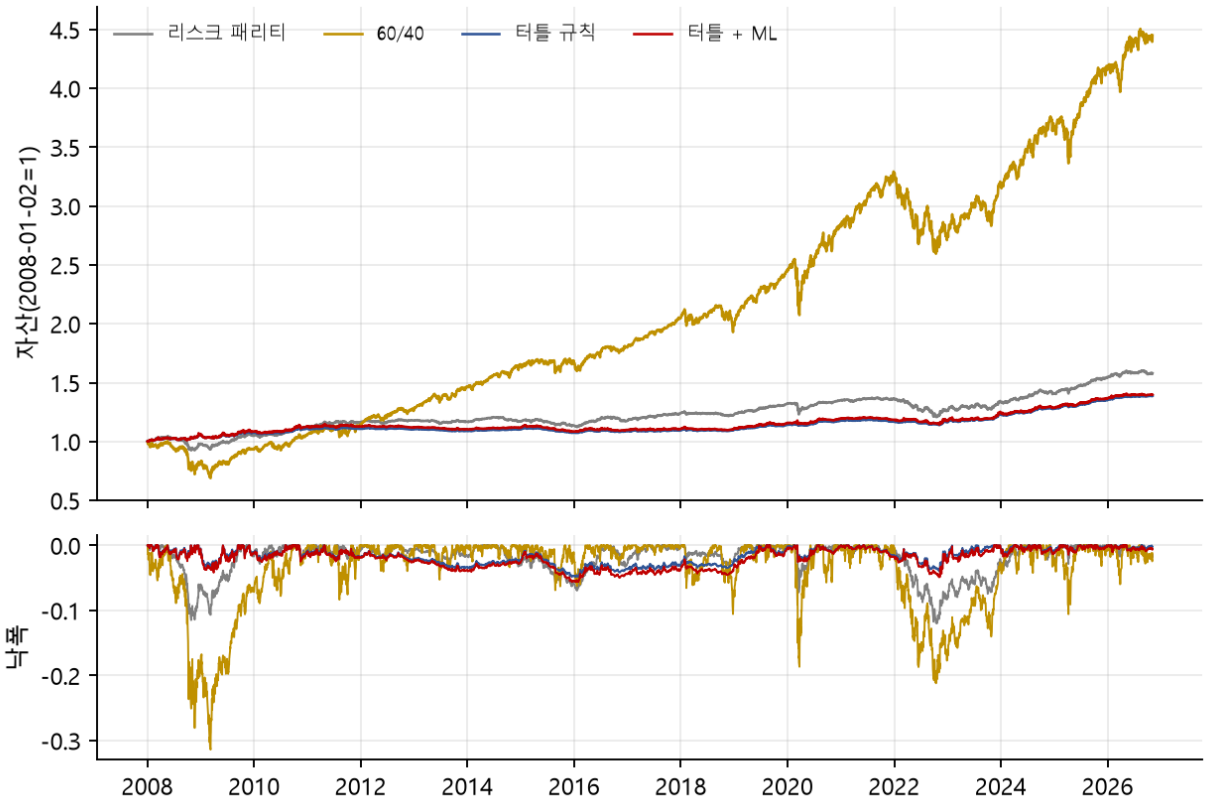
시세는 FinanceDataReader(야후)의 배당·분할 반영 수정종가, VIX·장단기 금리차·3 개월 국채 금리·환율은 FRED. 한국거래소(KRX) 요청은 없다. ETF 상장 전 구간은 아래 대용으로 이어 붙였고, 둘이 겹치는 기간의 차이를 점검했다(환율 대용은 처음 쓴 야후 환율의 주간 상관이 0.83 에 그쳐 FRED 뉴욕 정오 고시 환율로 바꿨다).

ETF	자산	상장일	상장 전 대용	겹친 기간	주간 상관	연 수익 차이
SPY	미국 대형주(S&P500)	1993-01-29	VFINX	34 년	0.995	0.00%
IWM	미국 소형주(러셀 2000)	2000-05-26	NAESX	26 년	0.987	0.85%
VGK	유럽 주식	2005-03-10	VEURX	22 년	0.994	-0.16%
EEM	신흥국 주식	2003-04-14	VEIEX	24 년	0.968	-0.12%
SHY	미국채 1~3 년	2002-07-30	VFISX	24 년	0.884	0.21%
IEF	미국채 7~10 년	2002-07-30	VFITX	24 년	0.959	-0.26%
TLT	미국채 20 년 이상	2002-07-30	VUSTX	24 년	0.987	0.11%
TIP	미국 물가연동채	2003-12-05	VIPSX	23 년	0.979	-0.14%
LQD	미국 투자등급 회사채	2002-07-30	VWESX	24 년	0.842	0.51%
HYG	미국 하이일드 회사채	2007-04-11	VWEHX	20 년	0.830	0.68%
GLD	금	2004-11-18	GC=F	22 년	0.983	0.46%
DBC	원자재 종합	2006-02-06	PCRIX	21 년	0.894	-0.62%
VNQ	미국 리츠	2004-09-29	VGSIX	22 년	0.998	-0.14%
UUP	달러 인덱스	2007-03-01	DX-Y.NYB	20 년	0.972	-0.76%
FXE	유로	2005-12-12	DEXUSEU	21 년	0.975	-0.34%
FXY	엔화	2007-02-13	DEXJPUS	20 년	0.974	0.48%

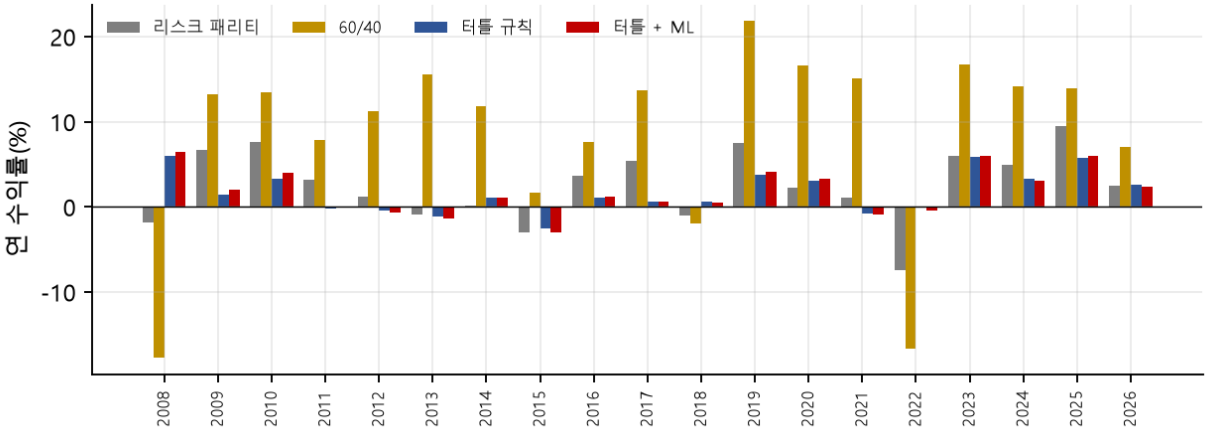
가격 단절 점검: 하루 ±25% 넘는 움직임은 ILF 2008-10-13(+26%), SLV 2026-01-30(-29%), USO 2020-03-09(-25%), 2020-04-21(-25%). 모두 실제 시장 사건(2008 년 반등, 2020 년 유가 폭락, 2026 년 은 급락)이라 보정하지 않았다(보정 건수 0 건). 대용이 없는 자산(나스닥 100·일본·한국·중국·인도·중남미·은·원유·농산물)은 ETF 상장 252 거래일 뒤부터 편입했다. 원유·은·농산물은 선물 연속가격을 이어 붙이면 만기 교체 때 가격이 튀어 가짜 돌파가 생기므로 쓰지 않았다.

4. 결과 (표본 밖 2008-01 ~ 2026-11)

전략	연 수익률	변동성	샤프	최대 낙폭	평균 투자 비중	연 회전율	리스크 패리티 대비 알파(t)
리스크 패리티	2.46%	3.8%	0.28	-12.0%	100%	0.5 배	-
60/40	8.26%	11.1%	0.64	-31.4%	100%	0.1 배	4.82% (3.21)
터틀 규칙	1.75%	2.4%	0.14	-4.9%	50%	5.1 배	-0.01% (-0.03)
터틀 + ML	1.79%	2.9%	0.14	-5.6%	60%	6.2 배	-0.03% (-0.05)



읽는 법: 리스크 패리티는 위험을 똑같이 나눠서 변동성이 낮은 자산에 돈이 몰린다. 표본 밖 평균 비중은 채권 55%(미국채 1~3 년만 31%), 통화 24%, 실물 11%, 주식 10%로, 레버리지 없이 쓰면 연 수익률이 낮다. 60/40 과는 위험 수준이 달라 수익률보다 샤프·최대 낙폭으로 비교하는 것이 맞다.



기간을 나눠 보면

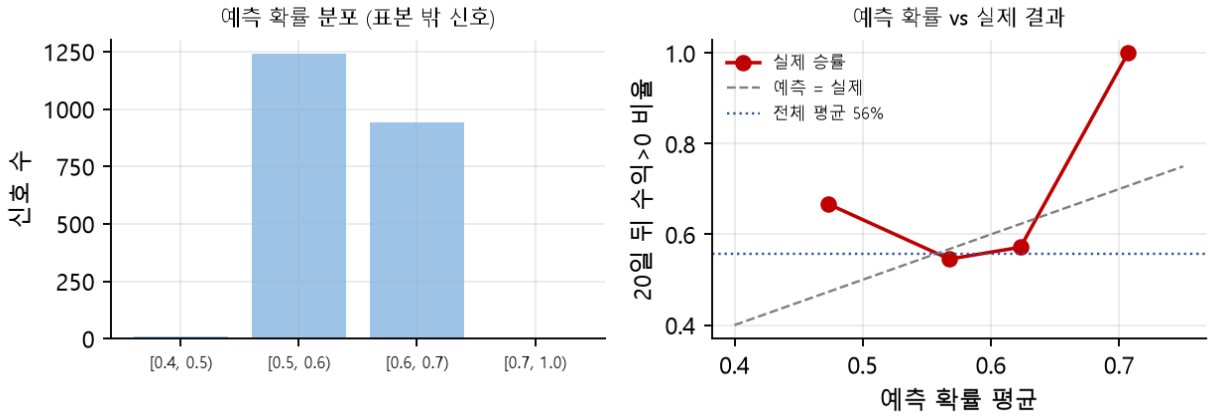
전략	표본 밖 2008-01~2026-11	전반 2008~2016	후반 2017~2026	전체 1998~2026
리스크 패리티	0.28 / -12.0%	0.44 / -11.5%	0.15 / -12.0%	0.45 / -12.0%
60/40	0.64 / -31.4%	0.61 / -31.4%	0.68 / -21.2%	0.53 / -32.2%
터틀 규칙	0.14 / -4.9%	0.28 / -4.9%	0.01 / -4.0%	0.40 / -4.9%
터틀 + ML	0.14 / -5.6%	0.28 / -5.6%	-0.00 / -4.9%	0.36 / -5.6%

칸 안 값: 샤프 / 최대 낙폭. 터틀은 학습 기간이 포함된 전체 기간에서 샤프가 더 높고, 2017 년 이후에는 거의 0 이다. 추세추종이 최근 10 년 횡보·급반등 장세에서 약했다는 뜻이다.

거래: 표본 밖 2,206 건(연 117 건, 자산당 연 4.7 건), 이긴 거래 34%, 거래당 평균 0.77%, 평균 보유 26 거래일. 승률이 낮고 소수의 큰 추세로 메우는 터틀의 구조가 그대로 나타났다.

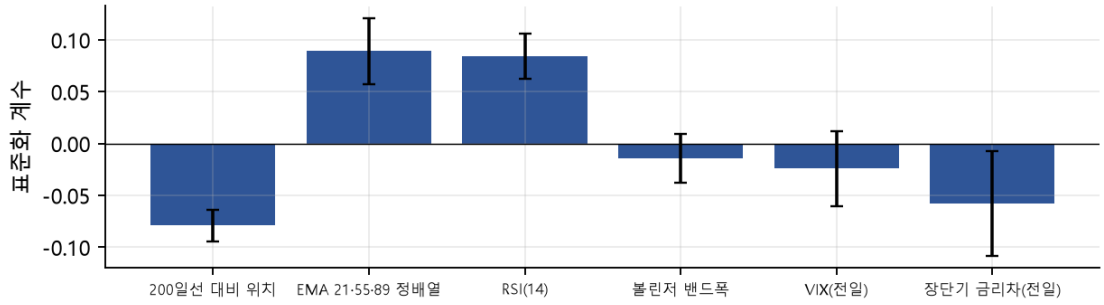
5. 머신러닝 진단

표본 밖 신호 2,195 개 중 20 거래일 뒤 수익이 난 비율은 55.8%이다. 모델의 예측 확률은 대부분 0.5~0.7 에 몰려 '진입 안 함(0.3 미만)'이 한 번도 나오지 않았고, 배수 2p 가 평균 1.2 배 정도라 ML 버전은 사실상 투자 비중만 늘어났다(평균 투자 비중 50% → 60%).

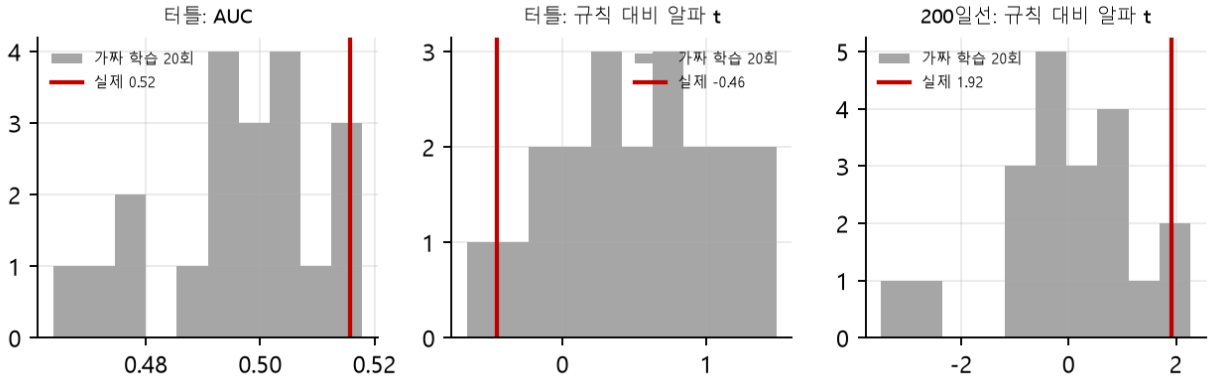


구분	신호 수	실제 승률	AUC
실물	559	50.8%	0.507
주식	838	58.8%	0.494
채권	523	59.7%	0.515
통화	275	49.1%	0.558
학습 때 있던 자산	2030	56.3%	0.517
학습 때 없던 자산(2008 년 이후 편입)	165	49.7%	0.491

AUC 는 '이긴 신호에 더 높은 확률을 줬는가'를 0~1 로 잰 값이다. 0.5 면 동전 던지기와 같다. 자산군별로도, 처음 보는 자산에서도 0.5 근처였다.



변수별 평균 계수(막대)와 해마다 다시 학습할 때의 흔들림(선). 정배열·RSI 는 19 번 모두 +, 200 일선 대비 위치는 19 번 모두 −로 부호가 일관됐다(이미 많이 오른 자산의 돌파는 덜 이긴다). 하지만 크기가 작다: 표준화 계수 0.09 는 그 변수가 1 표준편차 달라질 때 확률이 약 2%p 움직이는 정도다. 밴드폭·VIX·금리차는 해마다 부호가 바뀌었다(+로 나온 해 11%·26%·16%).



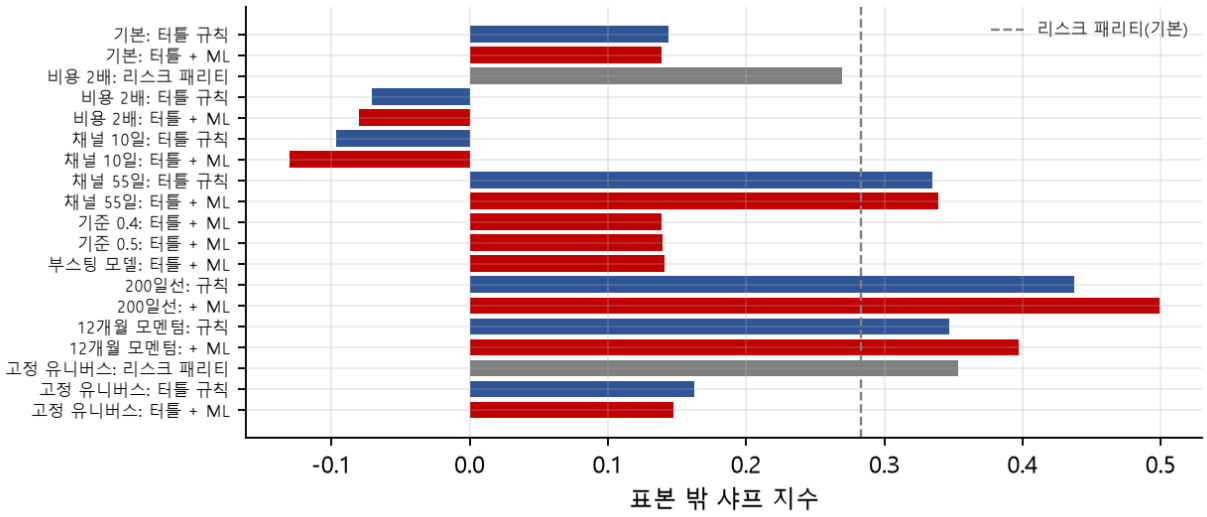
가짜 학습: 정답(20 일 뒤 수익 여부)을 무작위로 섞어 같은 절차로 20 번 학습했다. 실제 AUC 0.516 는 가짜 학습 분포(0.464~0.518) 안에 있다. 규칙 대비 알파 t 값도 가짜 학습(평균 0.50)이 오히려 높았다. 200 일선 + ML 의 t 1.92 도 가짜 학습 범위(-3.5~2.3) 안이어서, 성과 차이는 예측력이 아니라 비중이 달라진 효과로 본다.

6. 강건성 검증

조건을 바꿔도 결과가 유지되는지 확인했다. 아래 표의 모든 값은 표본 밖(2008-01~2026-11) 기준이다.

조건	연 수익률	샤프	최대 낙폭	평균 투자 비중	규칙 대비 알파 t
기본: 터틀 규칙	1.75%	0.14	-4.9%	50%	-
기본: 터틀 + ML	1.79%	0.14	-5.6%	60%	-0.46
비용 2 배: 리스크 패리티	2.41%	0.27	-12.1%	100%	-
비용 2 배: 터틀 규칙	1.23%	-0.07	-7.5%	50%	-
비용 2 배: 터틀 + ML	1.16%	-0.08	-9.3%	60%	-0.87
채널 10 일: 터틀 규칙	1.16%	-0.10	-6.9%	52%	-
채널 10 일: 터틀 + ML	1.03%	-0.13	-9.4%	62%	-1.44
채널 55 일: 터틀 규칙	2.20%	0.33	-3.1%	52%	-
채널 55 일: 터틀 + ML	2.33%	0.34	-3.5%	62%	0.33
기준 0.4: 터틀 + ML	1.79%	0.14	-5.6%	60%	-0.46
기준 0.5: 터틀 + ML	1.79%	0.14	-5.6%	59%	-0.27
부스팅 모델: 터틀 + ML	1.80%	0.14	-5.9%	60%	-0.05
상대 배수(p÷학습 승률): 터틀 + ML *	1.73%	0.13	-4.9%	52%	-0.82
정답=거래 실제 손익: 터틀 + ML *	1.65%	0.13	-3.7%	38%	-0.24
정답=거래 손익 + 상대 배수: 터틀 + ML *	1.69%	0.12	-4.9%	51%	-0.54
200 일선: 규칙	2.60%	0.44	-4.3%	70%	-
200 일선: + ML	2.96%	0.50	-4.8%	79%	1.92
200 일선: + ML 상대 배수 *	2.79%	0.48	-4.3%	73%	1.92
12 개월 모멘텀: 규칙	2.35%	0.35	-6.1%	71%	-
12 개월 모멘텀: + ML	2.64%	0.40	-6.1%	76%	1.40
12 개월 모멘텀: + ML 상대 배수 *	2.51%	0.39	-6.0%	69%	1.31
변수 확장 로지스틱: 터틀 + ML *	1.71%	0.11	-5.5%	59%	-0.79
변수 확장 로지스틱 + 정답=거래 손익: 터틀 + ML *	1.52%	0.06	-4.5%	32%	-0.47
변수 확장 부스팅: 터틀 + ML *	1.77%	0.13	-5.4%	58%	-0.21
변수 확장 부스팅 + 정답=거래 손익: 터틀 + ML *	1.48%	0.04	-3.7%	27%	-0.62
변수 확장 200 일선: + ML *	2.66%	0.39	-5.2%	78%	-0.55
변수 확장 12 개월 모멘텀: + ML *	2.74%	0.44	-6.0%	71%	1.65
고정 유니버스: 리스크 패리티	2.90%	0.35	-14.0%	100%	-
고정 유니버스: 터틀 규칙	1.84%	0.16	-4.3%	51%	-
고정 유니버스: 터틀 + ML	1.87%	0.15	-5.0%	61%	-1.26

* 사후 점검: 결과를 본 뒤 설계 문제(① 2p 배수가 투자 비중만 늘리는 문제, ② 정답을 '20 일 뒤 수익' 대신 그 거래의 실제 손익으로 두는 일반적인 메타 라벨링 방식)를 확인하려고 추가했다. 어느 쪽도 결론을 바꾸지 않았다.

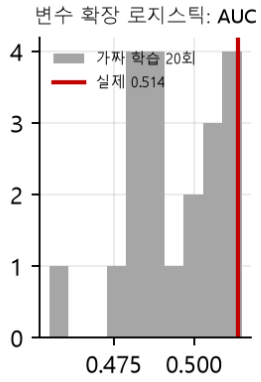


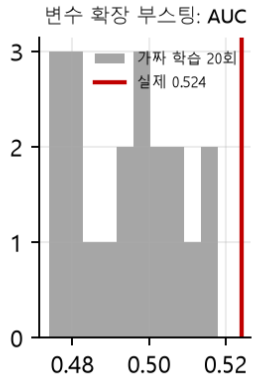
- 채널 길이: 10 일 -0.10 → 20 일 0.14 → 55 일 0.33. 짧을수록 거래가 많아 비용과 가짜 돌파에 약하다.
- 거래비용 2 배(0.1%): 터틀 샤프 -0.07. 연 회전율이 5.1 배라 비용에 민감하다.
- 유니버스: 1998 년 초에 이미 있던 13 개만 쓰면 터틀 샤프 0.16, 리스크 패리티 0.35. 늦게 들어온 자산에 기댄 결과가 아니다.
- 모델: 로지스틱 대신 그래디언트 부스팅도 AUC 0.490, 샤프 0.14 로 같았다.
- 신호 종류: 월간 200 일선 0.44, 12 개월 모멘텀 0.35 로 일간 20 일 돌파보다 좋았다. 월 1 회만 판단해서 가짜 돌파와 비용이 적은 것이 이유로 보인다.

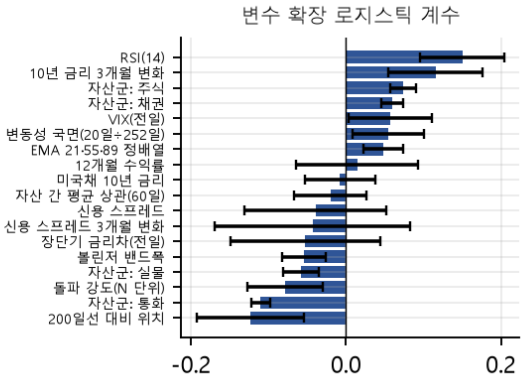
7. 변수 확장 후 재검증 (사후 점검)

기본 6 개 변수로 효과가 없다는 결과를 본 뒤, 다음 단계로 정한 변수 확장을 같은 가짜 학습 기준으로 다시 검증했다. 결과를 본 뒤 추가한 것이라 본 결과와 구분한다. 추가 변수: 신용 스프레드(무디스 Baa – 미국채 10 년, 수준·3 개월 변화), 미국채 10 년 금리(수준·3 개월 변화), 자산 간 평균 상관(60 일), 12 개월 수익률, 변동성 국면(20 일÷252 일), 돌파 강도(돌파 폭 ÷ N), 자산군 구분 4 개. 하이일드 스프레드는 FRED 가 최근 3 년치만 제공해 쓰지 못했다.

모델 · 정답	AUC	가짜 학습 AUC(평균 / 최고)	샤프	평균 투자 비중	규칙 대비 알파 t
로지스틱 · 20 일 뒤 수익	0.514	0.493 / 0.515	0.11	59%	-0.79
로지스틱 · 거래 실제 손익	0.491	-	0.06	32%	-0.47
부스팅 · 20 일 뒤 수익	0.524	0.494 / 0.518	0.13	58%	-0.21
부스팅 · 거래 실제 손익	0.487	-	0.04	27%	-0.62
200 일선 신호 · 로지스틱	0.449	-	0.39	78%	-0.55
12 개월 모멘텀 신호 · 로지스틱	0.537	-	0.44	71%	1.65
(참고) 기본 6 개 변수 · 로지스틱	0.516	0.496 / 0.518	0.14	60%	-0.46







- 부스팅 AUC 0.524 는 가짜 학습 20 회 중 가장 높은 값보다 조금 높아, 약한 예측력이 있을 가능성은 있다. 그러나 포트폴리오 성과는 개선되지 않았다(샤프 0.13 vs 규칙 0.14).
- 계수가 해마다 일관된 변수는 자산군 구분(통화 -0.11, 주식 +0.07), RSI(+0.15), 200 일선 대비 위치(-0.12), 돌파 강도(-0.08), 금리 3 개월 변화(+0.12)였다. 자산군 계수가 가장 안정적이라는 것은, 모델이 신호의 질보다 '주식은 원래 20 일 뒤 오를 확률이 높다'는 자산군별 평균 차이를 주로 배웠다는 뜻이다.
- 정답을 거래 실제 손익(승률 34%)으로 바꾸면 모델이 신호를 많이 걸러 투자 비중이 30% 안팎으로 줄고 샤프도 낮아졌다. 터틀은 낮은 승률을 소수의 큰 추세로 메우는 구조라, 이기는 거래를 맞히려는 필터가 큰 추세까지 걸러 버린 것으로 본다.
- 12 개월 모멘텀 + 변수 확장은 규칙 대비 t 1.65 였지만 2 에 못 미치고, 200 일선 가짜 학습에서 t 가 2 를 넘는 경우도 있었던 만큼 근거로 삼지 않는다.

8. 한계

- 달러 기준 수익률이다. 원화 투자자의 환율 효과와 세금은 넣지 않았다.
- ETF 상장 전 구간은 대용 펀드로 이어 붙였다. 회사채·하이일드 대용은 주간 상관 0.84·0.83 으로 차이가 있다(만기·신용등급 구성 차이).
- 리스크 패리티를 레버리지 없이 써서 채권·현금성 자산 비중이 높다. 수익률 수준은 레버리지 여부에 따라 크게 달라진다.
- ETF 목록은 2026 년 현재 상장된 상품에서 골랐다. 자산군을 빠짐없이 넣고 결과를 보기 전에 고정해서 사후 선택을 줄였지만 완전히 없앤 것은 아니다.
- 입력 변수는 기본 6 개, 확장 18 개까지 봤다. 거래량·수급·밸류에이션 같은 다른 종류의 변수와, 신호 성패 대신 다음 달 자산별 수익률을 직접 예측하는 방식은 다루지 않았다.
- 종가 기준 체결, 호가 차이는 고정 0.05%로 가정했다. 2008 년 같은 위기에는 실제 비용이 더 컸을 수 있다.

9. 결론

1) 다자산 터틀 추세추종은 2008·2022 년 같은 큰 하락장에서 손실을 거의 막았지만, 표본 밖 샤프는 단순 리스크 패리티보다 낮았다. 특히 2017 년 이후 성과가 거의 없었다.

2) 머신러닝으로 신호를 걸러 비중을 조절하는 방식은 기본 6 개 변수로도, 18 개로 늘려도 포트폴리오 성과를 개선하지 못했다. 예측력(AUC)은 정답을 섞은 가짜 학습과 거의 구별되지 않았고, 성과가 좋아 보인 경우(200 일선 + ML)도 가짜 학습 범위 안이었다.

3) 같은 틀에서 신호만 바꿔 보면, 월 1 회 판단하는 200 일선·12 개월 모멘텀이 일간 돌파보다 안정적이었다. 신호를 거르는 것보다 어떤 신호를 어떤 주기로 쓰느냐가 성과에 더 큰 영향을 줬다.

4) 이 프로젝트에서 가장 쓸모 있던 것은 검증 절차다: 상장 시점 기준 편입, 정답이 확정된 신호만 학습, 매년 재학습, 가짜 학습 대조. 이 절차가 있었기 때문에 '좋아 보이는 결과'(200 일선 + ML t 1.92, 부스팅 AUC 0.524)를 성과로 착각하지 않을 수 있었다.

코드: quant-strategy-lab/turtle_ml_allocation (universe·data·signals·backtest·ml·run). 같은 데이터면 같은 결과가 나온다(난수 고정).